AKUISISI, KUALITAS DATA, DAN EXPLORATORY DATA ANALYSIS

LAPORAN TUGAS 2

ANALISIS FAKTOR-FAKTOR YANG BERHUBUNGAN DENGAN PERTUMBUHAN EKONOMI NEGARA BERDASARKAN WORLD DEVELOPMENT INDICATORS

Kelompok 10

Haykal Ilyas

NIM: 2410631250012

Muhammad Hanif Abdillah

NIM: 2410631250099

Mata Kuliah: Pengantar Big Data

Program Studi: Sistem Informasi

Universitas Singaperbangsa Karawang

2026

1. Pendahuluan

Tugas ini berfokus pada akuisisi, pemeriksaan kualitas, pembersihan, transformasi, dan eksplorasi data World Development Indicators (WDI) yang diterbitkan oleh World Bank. Analisis diarahkan untuk memahami karakteristik GDP Growth serta hubungan awalnya dengan GDP per Capita, Unemployment, Internet Users, Population, dan Foreign Direct Investment (FDI).

Tujuan pengerjaan adalah memperoleh dataset yang dapat ditelusuri sumbernya, mendokumentasikan kualitas data, menerapkan proses cleaning yang dapat dijalankan ulang melalui kode, serta menghasilkan statistik dan visualisasi untuk mendukung analisis berikutnya.

2. Sumber dan Akuisisi Data

Sumber data adalah World Bank, melalui API indikator World Development Indicators. Data diambil dalam format JSON untuk periode 2015–2024. Akuisisi mencakup enam indikator berikut:

Nama variabel	Kode indikator World Bank	Satuan
GDP_Growth	NY.GDP.MKTP.KD.ZG	Persen (%)
GDP_per_Capita	NY.GDP.PCAP.CD	US$ per kapita
Unemployment	SL.UEM.TOTL.ZS	Persen (%)
Internet_Users	IT.NET.USER.ZS	Persen (%)
Population	SP.POP.TOTL	Jiwa
FDI	BX.KLT.DINV.WD.GD.ZS	Persen terhadap GDP (%)

Parameter akuisisi: periode 2015–2024, format JSON, parameter API per_page=20000, timeout 180 detik, dan maksimal tiga percobaan ulang. Manifest akuisisi mencatat status pengambilan data dan checksum berkas.

Tanggal akses yang tercatat pada manifest adalah 11 November 2026.

Data mentah disimpan di data/raw/world_bank_wdi/ dalam bentuk JSON. Berkas raw dipertahankan tanpa pengeditan manual agar proses dapat direproduksi.

Sumber utama: World Bank Data Catalog – World Development Indicators.

3. Data Dictionary dan Unit Analisis

Dataset terolah menggunakan kolom country, countryiso3code, date, GDP_Growth, GDP_per_Capita, Unemployment, Internet_Users, Population, dan FDI. Unit analisis atau grain adalah satu negara pada satu tahun. Kunci identifikasi observasi adalah kombinasi

countryiso3code dan date (tahun). GDP_Growth menjadi variabel target, sedangkan lima indikator lainnya menjadi variabel prediktor.

Data WDI dapat memiliki nilai kosong karena ketersediaan indikator berbeda antarnegara dan tahun. Nilai kosong tidak diisi secara manual; dataset utama mempertahankan missing values dan dataset tambahan wdi_complete.csv menyimpan baris yang lengkap pada keenam indikator.

4. Data Profiling dan Kualitas Data

Profiling dilakukan terhadap nilai kosong, duplikasi, statistik deskriptif, tipe data, dan kandidat outlier. Hasil pemeriksaan duplikasi berdasarkan identitas negara dan tahun menunjukkan nol duplikasi untuk keenam indikator. Pemeriksaan awal sempat mendeteksi duplikasi semu karena baris agregat memiliki kode ISO3 kosong; identifikasi diperbaiki dengan menggunakan label negara untuk keperluan profiling, kemudian dataset utama difokuskan pada negara individual.

4.1 Missing Values Setelah Cleaning

Variabel	Missing	Persentase
GDP_Growth	85	3,26%
GDP_per_Capita	81	3,10%
Unemployment	309	11,84%
Internet_Users	446	17,09%
Population	0	0,00%
FDI	217	8,31%

Internet_Users memiliki persentase missing values tertinggi sebesar 17,09%, sedangkan Population tidak memiliki nilai kosong pada dataset hasil cleaning. Missing values dipertahankan agar tidak menambahkan asumsi atau nilai buatan ke dalam data.

4.2 Outlier dan Tipe Data

Kandidat outlier dicatat dalam potential_outliers.csv menggunakan pendekatan rentang interkuartil (IQR). Nilai ekstrem tidak langsung dihapus karena dapat merepresentasikan kondisi ekonomi nyata atau kejadian luar biasa. Pemeriksaan lanjutan perlu mempertimbangkan konteks indikator dan sumbernya. Tipe data variabel numerik diperiksa dan dikonversi ke tipe numerik sebelum analisis.

5. Data Cleaning, Integrasi, dan Transformasi

Proses cleaning dilakukan melalui skrip src/analysis/03_data_cleaning.py. Untuk setiap indikator, data berisi 2.660 record, terdiri atas 2.610 record negara individual dan 50 record agregat. Record agregat dikeluarkan dari dataset utama karena fokus penelitian adalah negara individual. Penggabungan dilakukan berdasarkan kode ISO3 dan tahun.

Hasil proses adalah 2.610 baris dalam wdi_cleaned.csv dan 1.967 baris lengkap dalam wdi_complete.csv. Tidak ada duplikasi pada kunci negara-tahun dalam pemeriksaan cleaning. Ringkasan proses disimpan pada cleaning_summary.csv, missing_values_after_cleaning.csv, dan excluded_aggregates.csv di folder data/processed/.

6. Exploratory Data Analysis (EDA)

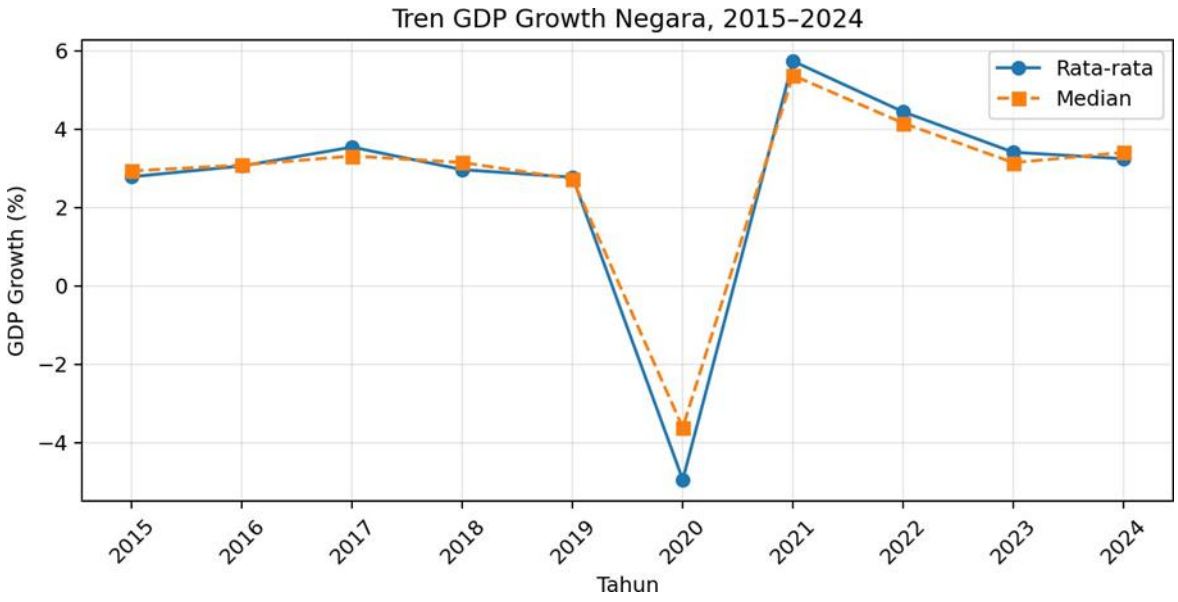
EDA dilakukan melalui skrip src/analysis/04_eda.py. Analisis mencakup statistik deskriptif, tren tahunan, distribusi GDP Growth, matriks korelasi Pearson, scatter plot hubungan target-prediktor, serta perbandingan negara dengan rata-rata GDP Growth tertinggi dan terendah.

6.1 Statistik Deskriptif

Variabel	Data tersedia	Rata-rata	Minimum	Maksimum
GDP Growth	2.525	2,70%	-54,40%	75,31%
GDP per Capita	2.529	US$17.954,61	US$216,23	US$288.001,57
Unemployment	2.301	7,32%	0,10%	36,47%
Internet Users	2.164	59,98%	1,08%	100,00%
Population	2.610	293,26 juta	9.646	8,14 miliar
FDI	2.393	6,01%	-1.303,11%	1.709,83%

Rata-rata GDP Growth adalah 2,70% dengan median 3,13%. Rentang nilai yang lebar menunjukkan adanya variasi besar antarnegara dan tahun. Nilai ekstrem sebaiknya ditinjau dengan konteks sebelum menentukan perlakuan lebih lanjut.

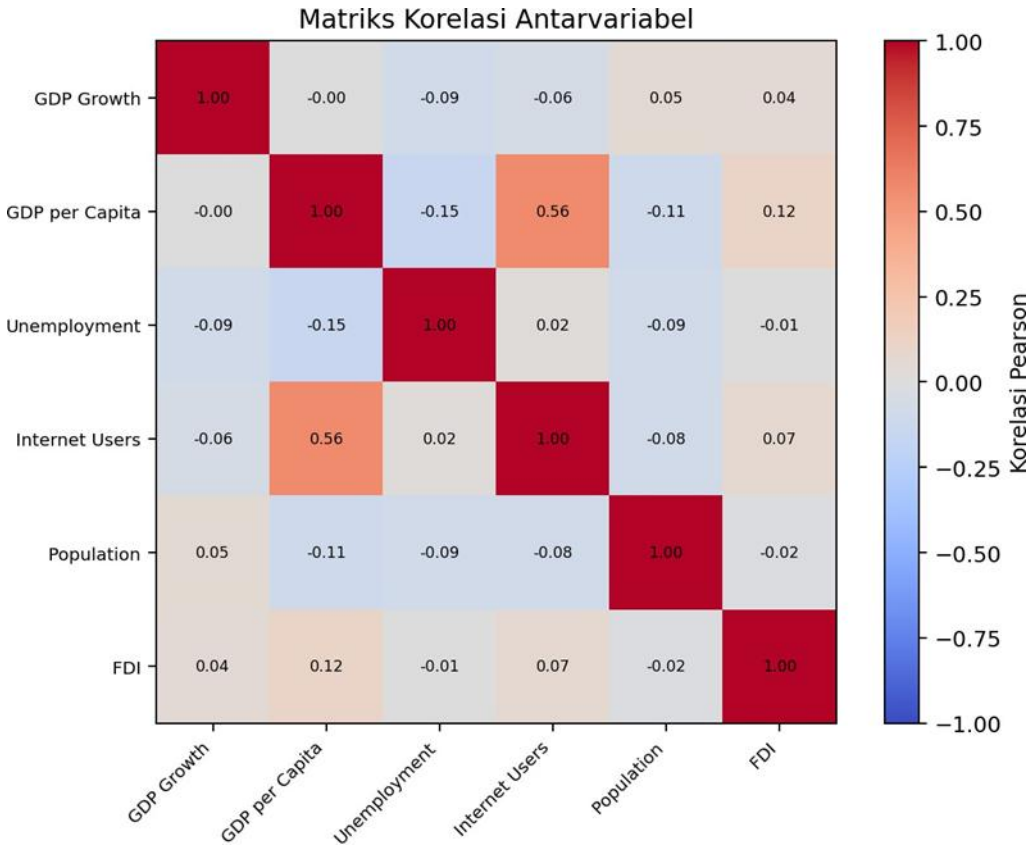
6.2 Tren GDP Growth per Tahun



Gambar 1. Rata-rata dan median GDP Growth tahunan 2015–2024.

Rata-rata GDP Growth tertinggi terjadi pada 2021 sebesar 5,74%, sedangkan terendah terjadi pada 2020 sebesar -4,95%. Penurunan 2020 bertepatan dengan periode pandemi COVID-19; pola ini konsisten dengan kontraksi ekonomi global pada masa tersebut, tetapi grafik deskriptif ini sendiri tidak menguji sebab-akibat. Setelah itu rata-rata kembali positif pada 2021.

6.3 Korelasi Antarvariabel



Gambar 2. Matriks korelasi Pearson antar enam indikator.

Prediktor	Korelasi dengan GDP Growth	Interpretasi awal
GDP per Capita	-0,001	Hampir tidak ada korelasi linear
Unemployment	-0,086	Negatif sangat lemah
Internet Users	-0,061	Negatif sangat lemah
Population	0,049	Positif sangat lemah
FDI	0,042	Positif sangat lemah

Seluruh prediktor menunjukkan korelasi Pearson yang sangat lemah dengan GDP Growth pada data gabungan negara dan tahun. Korelasi paling menonjol di antara pasangan variabel selain diagonal adalah GDP per Capita dengan Internet Users (sekitar 0,565), yang menunjukkan hubungan positif sedang. Korelasi tidak membuktikan sebab-akibat dan hasil gabungan ini belum mengendalikan perbedaan karakteristik tiap negara.

6.4 Keterbatasan EDA

Jumlah negara dengan data GDP Growth yang tersedia berubah setiap tahun, dari 255 pada 2015 menjadi 244 pada 2024. Karena itu, rata-rata tahunan dihitung berdasarkan data yang tersedia pada masing-masing tahun dan komposisi negara tidak sepenuhnya sama. Analisis korelasi Pearson hanya menggambarkan hubungan linear sederhana; analisis lanjutan

diperlukan untuk menilai pola non-linear, perbedaan antarnegara, dan faktor lain yang tidak tercakup dalam dataset.

7. Kesimpulan

Akuisisi dan pengolahan data WDI berhasil menghasilkan dataset negara individual yang berisi 2.610 observasi untuk enam indikator pada periode 2015–2024. Data profiling menemukan missing values yang berbeda

antarindikator, tidak menemukan duplikasi pada kunci negara-tahun setelah identitas ditangani dengan benar, dan mencatat kandidat outlier untuk pemeriksaan lebih lanjut. Data cleaning memisahkan agregat dari negara individual serta mengintegrasikan indikator berdasarkan kode negara dan tahun.

EDA menunjukkan rata-rata GDP Growth sebesar 2,70%, penurunan rata-rata pada 2020, dan pemulihan pada 2021. Korelasi Pearson antara masing-masing prediktor dan GDP Growth sangat lemah dalam data gabungan. Hasil ini menjadi gambaran awal dan tidak dapat digunakan untuk menyimpulkan hubungan sebab-akibat.

8. Kendala dan Solusi

Kendala pertama adalah baris agregat World Bank yang tidak memiliki kode ISO3 sehingga pemeriksaan duplikasi awal menghasilkan duplikasi semu. Solusinya adalah memperbaiki identifikasi untuk profiling dan mengecualikan agregat dari dataset utama. Kendala kedua adalah missing values pada sejumlah indikator; nilai kosong dipertahankan dan didokumentasikan, bukan diisi secara manual. Kendala ketiga adalah nilai ekstrem pada beberapa indikator; nilai tersebut dicatat sebagai kandidat outlier dan tidak langsung dihapus.

9. Kontribusi Pribadi

Muhammad hanif berkontribusi pada analisis EDA, statistik deskriptif, visualisasi data, dan penyusunan laporan.

Haykal Ilyas berkontribusi pada akuisisi data, data profiling, data cleaning, pengelolaan repositori GitHub dan dokumentasi persiapan data.

10. Repository dan Reproduksibilitas

Repository GitHub: project-big-data-kelompok-10.

Dokumen Tugas 1: folder docs/milestone/tugas-1.

Release/tag Tugas 2: belum dicantumkan karena perlu dibuat pada GitHub setelah seluruh file Tugas 2 di-push. Setelah tag/release tugas-2 dibuat, masukkan URL-nya pada bagian ini dan pada salinan akhir laporan.

Data dan kode disimpan secara terstruktur agar proses akuisisi, profiling, cleaning, dan EDA dapat dijalankan ulang. Dataset WDI dapat diperbarui oleh World Bank, sehingga tanggal akses dan manifest akuisisi digunakan untuk mendukung keterlacakan proses.

Daftar Pustaka

World Bank. (n.d.). World Development Indicators. World Bank Data Catalog. https://datacatalog.worldbank.org/search/dataset/0037712/world-development-indicators

World Bank. (n.d.). World Bank Indicators API. https://api.worldbank.org/